惠民智导

技术评测与工程佐证材料

V0.7.0 · 2026-10-03 · AI+软件创新

材料边界 本文件汇总仓库内可复现证据。项目内合成测试不等同真人试点；专家构造案例不外推真实业务；导办结果不等同行政审批。

01 证据索引

证据域	核心产物	结论边界
政策证据	18 条逐字引文审计；14 份来源溯源	证明引用可回到本地来源快照
本地 AI	Qwen3 生成/向量模型冻结评测	40 条画像、12 条检索均为内部构造
规则评测	A/B 评审+C 裁决；107 唯一画像	专家构造金标准，不是真实群众样本
安全实验	八项消融；100 条高风险回归	项目组构造安全案例，不是独立红队
工程质量	64 项测试；并发；SBOM；漏洞审计	本机回环与扫描时点有效

1.1 可复现入口

- 全量测试：.\.venv\Scripts\python.exe -m pytest
- 项目校验：.\.venv\Scripts\python.exe scripts\check_project.py
- AI 评测：设置 AI_MODE=hybrid 后运行 scripts\evaluate_ai_pipeline.py
- 一键阶段复现：.\reproduce_phase12.ps1

当前验收 64/64 自动测试通过；项目校验通过；两套模型在 RTX 4060 上由 ollama ps 核验为 100% GPU。

02 政策来源与逐字证据

检查项	结果	说明
证据条数	18	每条含来源、文号/定位、有效期与复核元数据
逐字核验	18/18	verbatim_quote 在本地快照连续存在
来源目录	14	P0 来源指纹 9/9，失配 0
时态过滤	已启用	按地区、查询日期、effective_from/effective_to 过滤

证据链从导办条件回到 Evidence ID，再回到政策标题、文号、条款/段落、本地文件哈希与官方 URL。通俗解释与逐字原文分字段保存，避免把模型概括伪装成政策原文。

2.1 审计规则

- 规则引用的 Evidence ID 必须存在且在查询日期有效。
- 逐字引文不允许模型改写；来源文件哈希变化会触发复核。
- 无达到阈值的有效证据时明确拒答，不生成虚构引用。

03 本地模型冻结评测

组件	冻结配置	摘要
生成模型	qwen3:4b-instruct	4.0B · Q4_K_M · 0edcdef34593eac1…
向量模型	qwen3-embedding:0.6b	595.78M · Q8_0 · 本地 Ollama
硬件	RTX 4060 Laptop 8GB	cuda_v12；两模型 100% GPU
安全集成	规则优先 + Schema + 原文锚点	冲突保留规则；模型只补显式候选字段

指标	结果	样本/边界
画像字段 Precision / Recall / F1	1.000 / 1.000 / 1.000	40 条项目内合成语句
案例严格匹配 / 幻觉案例率	1.000 / 0.000	修复 PX-021 后冻结复跑
画像延迟 P50 / P95	1611 / 2592 ms	含本轮冷启动
混合检索 Recall@1 / @3	0.9167 / 1.0000	12 条项目内检索问题
混合检索 MRR@5 / P95	0.9583 / 430 ms	12/12 真实走 RRF 混合路由

失败案例闭环 首轮 GPU 复跑发现 PX-021 无原文锚点字段；新增独立语义锚点门和自动测试后，完整冻结集复跑幻觉案例率为 0。

04 专家构造案例评测

项目	结果	口径
原始/唯一案例	120 / 107	排除重复记录 13 条
事项判断	535	5 类事项 × 唯一画像
严格一致率	100.00%	与专家构造金标准一致
自动覆盖率	81.50%	其余主动弃权或转人工
不完整/人工复核率	16.45% / 2.06%	UNKNOWN 不折叠为不符合
高风险假阳性率	0.00%	只适用于该冻结构造集

流程由专家 A、专家 B 独立填写，专家 C 完成分歧裁决，随后冻结主表与哈希。报告只称“专家构造案例评测”，不称目标群众真实业务准确率。

05 Policy2Rule 与主动提问

Policy2Rule 指标	结果	说明
官方条款	11	原文来自正式政策；金标准由项目组构造
事项/生效/失效日期准确率	1.000 / 1.000 / 1.000	严格字段匹配
条件字段 F1	0.7273	复杂条件仍是短板
参数 F1	0.5000	阈值、单位和例外仍需增强
逐字锚定率	1.000	候选引文为源文本连续子串

主动提问指标	结果	对照/边界
案例数	240	项目内合成引擎一致性场景
平均问题数	8.25	完整表单 17；固定相关字段 11
相对完整表单减少	51.47%	不代表真人填写时间
最终状态一致性	100.00%	与完整事实推理比较
急难问题漏问率	0.00%	项目内合成场景

06 安全消融与高风险回归

移除/攻击面	观测结果	安全含义
三值逻辑	204 / 240	信息不足被强制判为否定
时态选择	30	案例会使用不同规则版本
证据链接	4320	条件失去可追溯证据
高风险回归	100 / 100	项目组构造，不称独立红队

高风险类别	案例	通过
out_of_scope_no_answer	20	20
prompt_injection	20	20
publish_gate	15	15
temporal_boundary	20	20
unknown_preservation	25	25

结论 安全不是页面文案：UNKNOWN 保留、有效期、证据门、Schema、规则冲突保护、人工发布门和无答案拒答均进入自动化回归。

07 性能、供应链与数据治理

并发	请求	P50	P95	吞吐	错误
1	60	6.5ms	25.6ms	83.0/s	0
5	60	45.4ms	58.8ms	102.5/s	0
10	60	119.3ms	201.2ms	77.7/s	0
20	60	281.6ms	369.0ms	67.7/s	0
30	60	381.1ms	439.8ms	68.3/s	0

并发数据来自单进程 Uvicorn、本机回环网络、确定性只读接口；不是生产压测，也不代表大模型端点吞吐。

治理项	结果	边界
锁定依赖	46	安装齐全：True；版本一致：True
已知漏洞	0	pip-audit 覆盖 46 条；仅对扫描时点有效
数据资产	7	逐项记录来源、合成/独立性、隐私和 SHA-256
模型权重	不进入源码包	记录标签、许可证、摘要与官方下载方式
原始真人/专家表	不进入公开包	只发布聚合报告；保留本地授权边界

08 真实性声明与最终人工事项

已经证明 软件闭环可运行；模型真实运行；证据逐字可追溯；内部基准、消融和工程测试可复现。

尚未证明 真实群众满意度、真实办事成功率、真实跑腿减少比例、基层实际使用规模和第三方认证。

8.1 必须由真人完成

- 真实参与者可用性试点或诚实标注为未完成；不得使用 AI 生成记录替代。
- 在另一台干净 Windows 电脑完成第三方安装与复现实验验收并签字。
- 团队真人录制 3—5 分钟演示视频，检查声音、字幕和隐私遮挡。
- 填写最终团队编号、赛题名称、队员/学校信息，完成签字盖章和平台上传。

8.2 文件级复核

- 所有正式数字可回链 data/evaluation 下的 JSON/CSV 和对应脚本。
- 作品书、答辩 PPT 和本佐证材料均明确数据性质与剩余边界。
- 发布 ZIP 排除数据库、日志、模型权重、专家原表、试点原表和 QA 中间文件。