# 惠民智导

## 可信政策智能软件平台

AI + 软件创新赛道 · 作品方案

**一句话定义** 采用受约束神经符号架构，把本地模型、时态规则、三值逻辑、混合检索、政策编译与独立安全校验组合为可追溯、可拒答、可回归验证的政策智能软件。

**参赛团队：策马奔腾队**

版本：V0.7.0 | 文档日期：2026-10-03

数据科学与大数据技术 · 三人团队 · 单机 RTX 4060

# 作品摘要

社会救助政策专业、分散且持续更新，群众难以判断“当前适用哪一版、还缺什么信息、依据在哪里”，基层人员也面临重复解释、规则维护和错误传播风险。惠民智导将社会救助作为首个深度验证场景，构建政策摄取、Policy2Rule 候选编译、时态规则推理、主动提问、证据检索、材料预检、影响分析与人工发布门的一体化平台。

系统坚持“模型理解、规则裁决、原文举证、人工发布”：模型只做意图识别、信息抽取和候选结构化；资格结果由版本化规则与三值逻辑计算；独立校验器阻止无证据结论、越权审批和提示注入；每个结论均回链逐字政策原文。

**可信边界** 本方案不宣称已取得真实群众应用成效。现有数字来自项目内合成测试、官方条款基准和专家构造金标准；真人试点与第三方证明作为赛前外部验证任务单独管理。

## 核心成果速览

| 维度 | 当前可验证结果 | 证据文件 |
| --- | --- | --- |
| 安全 | 高风险集 100/100 通过 | high_risk_safety_report.json |
| 检索 | 内部基准 R@3=1.000，MRR=0.958 | retrieval_report.json |
| 主动提问 | 240 合成案例；较 17 字段表单减少 51.47% | active_question_report.json |
| 政策编译 | 11 条官方条款；原文锚定率 1.000 | policy_compiler_real_report.json |
| 并发 | 1/5/10/20/30 并发零错误；30 并发 P95 439.8ms | http_concurrency_report.json |
| 工程 | 64 项自动测试通过；锁定依赖 46 项；已知漏洞 0 | pytest / vulnerability report |

# 目录

01 问题与价值

02 产品与用户旅程

03 总体架构

04 AI 核心创新

05 可信安全机制

06 数据与知识治理

07 功能系统

08 实验设计与结果

09 工程实现

10 差异化与推广

11 风险与伦理

12 实施与分工

13 提交清单与边界

# 01 问题与价值

## 1.1 社会痛点

| 对象 | 高频痛点 | 传统方式的限制 |
| --- | --- | --- |
| 困难群众 | 术语难懂、条件繁多、材料不清、政策版本难辨 | 网页搜索和电话咨询难形成个性化、可追溯结论 |
| 基层经办 | 重复问询、信息缺失、口径更新不一致 | 静态问答库无法表达例外、缺失值与时间边界 |
| 政策管理者 | 政策转规则慢，变更影响不可见 | 人工维护难发现冲突，发布前缺少回归验证 |
| 监督者 | 难追溯结论由来，模型可能自信编造 | 通用大模型缺少发布权边界和原文级证据链 |

## 1.2 项目价值

- 把“查政策”升级为“问最少的问题—保留不知道—给出下一步—回链原文”。
- 把“写规则”升级为“模型候选抽取—Schema 校验—原文锚定—影响分析—人工双审”。
- 把“模型回答”约束为不越权的辅助决策，避免将导办误包装为审批。
- 以社会救助验证通用内核，可迁移至医保、助学、养老、就业补贴等政策服务。

## 1.3 目标用户与边界

居民端提供资格预判、信息补问、材料清单和办理指引；经办端提供结构化摘要、证据核对和人工复核；治理端提供政策版本、候选规则、影响分析与发布门。系统输出均为导办建议，不替代政府审批，不生成虚假证明，不收集非必要身份信息。

# 02 产品与用户旅程

| 阶段 | 系统动作 | 可信产物 |
| --- | --- | --- |
| 1. 表达诉求 | 自然语言输入或选择示例家庭 | 意图、地区、查询日期、已知事实 |
| 2. 主动补问 | 按预期信息增益选择下一问题，可跳过 | UNKNOWN 保留，不强迫猜测 |
| 3. 资格预判 | 时态规则 + 三值逻辑 + 独立校验 | 符合/可能符合/信息不足/需人工复核 |
| 4. 原文举证 | BM25/混合检索，按日期过滤政策版本 | 逐字引文、来源、定位、哈希 |
| 5. 材料预检 | OCR 抽取候选字段，人工确认 | 缺件提醒与风险提示，不替代原件 |
| 6. 办理导向 | 匹配办事机构和事项 | 地址、电话、材料清单、行动步骤 |
| 7. 政策更新 | Policy2Rule 候选编译与影响分析 | 差异报告、回归结果、人工发布记录 |

**演示闭环** 评委可在“评审演示中心”按 A–F 六个案例复现：正常家庭、信息不足、紧急风险、政策版本差异、候选规则影响分析、越权/注入拒绝。

# 03 总体架构

| 层级 | 关键组件 | 设计原则 |
| --- | --- | --- |
| 交互层 | 居民端、经办端、评审演示中心、治理工作台 | 同一事实模型，不做孤立演示页 |
| AI 理解层 | 意图分类、字段抽取、OCR、候选政策编译 | 模型输出仅为候选，统一 Schema 约束 |
| 推理层 | 时态规则、三值逻辑、主动提问、冲突检测 | 确定性可复现；UNKNOWN 为一等状态 |
| 证据层 | 政策切片、版本选择、BM25/向量接口、逐字引文 | 结论必须有原文证据；过期版本隔离 |
| 安全层 | 独立校验器、越权检测、注入防护、人工发布门 | 失败时拒答或降级，不静默放行 |
| 工程层 | FastAPI、SQLite、审计日志、离线部署、CI | 单机可运行、可测、可打包、可复现 |

### 3.1 受约束神经符号路线

神经模型擅长理解自然语言和生成结构化候选；符号规则擅长处理政策阈值、例外、时间和可复现裁决。系统以“候选—校验—发布”隔离两者：任何模型输出都不能直接进入正式规则库，也不能绕过证据与人工复核。

| 输入 | AI 处理 | 约束 | 输出 |
| --- | --- | --- | --- |
| 群众描述 | 意图与事实抽取 | 字段白名单、拒绝注入 | 候选事实 + 置信度 |
| 政策原文 | 条款切分与规则候选 | Schema、原文子串、类型检查 | 待审候选规则 |
| 咨询问题 | 语义召回候选 | 日期/地区过滤、原文引用 | 证据片段与来源 |
| 家庭事实 | 不由大模型裁决 | 时态规则 + 三值逻辑 | 可解释导办状态 |

## 04 AI 核心创新

### 4.1 Policy2Rule：政策原文到候选规则

系统从官方条款中抽取适用对象、条件字段、比较符、阈值、例外、有效期和逐字证据，生成候选规则。候选必须通过 JSON Schema、字段白名单、运算符白名单、证据子串校验和版本完整性检查，之后才能进入影响分析和人工双审。

| 创新点 | 实现 | 避免的风险 |
| --- | --- | --- |
| 逐字锚定 | candidate.evidence_quote 必须是源文档连续子串 | 模型“总结正确但出处虚构” |
| 类型化条件 | 字段、运算符和值独立建模 | 自然语言规则不可计算 |
| 版本化发布 | effective_from/to + region + source hash | 新旧政策混用 |
| 影响分析 | 候选规则对冻结案例集批量回放 | 修改一个阈值导致隐蔽回归 |
| 人工发布门 | 模型无 publish 权限，异常候选自动阻断 | 自动化越权发布 |

### 4.2 主动信息增益提问

系统不固定询问全部字段，而是计算每个缺失事实对候选事项状态的区分能力，优先询问能最大幅度减少不确定性的字段。用户可选择“不知道/跳过”，系统不会把未知值改写为否定值。

### 4.3 时态证据检索

检索前先按地区和查询日期筛选适用版本，再在适用政策片段上执行关键词或向量召回；过期、未生效和跨地区片段进入排除列表，可在界面解释“为何未采用”。这使检索不仅回答“相关不相关”，还回答“在这个日期是否有效”。

### 4.4 独立安全验证

最终输出由与生成模块分离的验证器检查：是否越权声称审批、是否包含无来源结论、是否遗漏紧急求助提示、是否将 UNKNOWN 强制二值化、是否响应提示注入、是否尝试自动发布。失败时返回受控拒答或人工复核。

**AI 的真正贡献** 创新不是给网页加聊天框，而是让模型进入政策编译和证据检索的高价值环节，同时用符号约束、时间边界和独立校验把生成式风险关进工程护栏。

## 05 可信安全机制

| 机制 | 触发条件 | 系统行为 | 可验证证据 |
| --- | --- | --- | --- |
| 三值逻辑 | 关键字段缺失 | 返回 UNKNOWN/信息不足并继续补问 | ablation_report.json |
| 时态选择 | 同政策多版本 | 仅选择查询日期有效版本 | retrieval benchmark |
| 证据门 | 结论无逐字引文 | 阻断或转人工 | evidence_quote_audit.json |
| 注入防护 | 要求忽略规则/伪造身份 | 不提取关键事实，保留警示 | 100 例安全集 |
| 发布门 | 候选规则请求直接生效 | 禁止自动发布，要求双审 | publish gate tests |
| 越权防护 | 询问是否“已批准” | 声明仅供导办，不替代审批 | out-of-scope tests |

| 机制 | 触发条件 | 系统行为 | 可验证证据 |
| --- | --- | --- | --- |
| 安全降级 | 本地模型不可用 | 切回确定性管线并显示真实状态 | AI readiness endpoint |

### 5.1 高风险测试集

项目构建 100 条项目内高风险测试，覆盖 UNKNOWN 保留 25 条、时间边界 20 条、越权问题 20 条、提示注入 20 条和发布门 15 条。当前版本通过 100/100。该结果用于开发回归，不等同于独立红队或真实群众试点。

### 5.2 消融证明

八组消融实验分别关闭三值逻辑、时态选择、证据门、Schema、冲突检测、主动提问、人工发布门和越权防护，观察不安全输出或额外负担。关闭二值保护会迫使 204/240 个信息不足案例产生武断结果；关闭证据门会使 4320 个条件失去可追溯证据；固定提问平均额外增加 2.75 个问题。

## 06 数据与知识治理

数据资产按来源、用途、是否独立、是否含个人信息、哈希和生成方式登记。官方政策文档保留本地快照、来源链接、发布日期、适用地区和 SHA-256；评测数据区分官方条款、专家构造金标准和项目内合成数据。

| 资产类型 | 来源 | 用途 | 声明 |
| --- | --- | --- | --- |
| 政策证据包 | 政府公开文件/网页本地快照 | 规则和证据 | 逐字引用并记录哈希 |
| 专家金标准 | 专家 A/B 标注与 C 裁决 | 确定性推理评测 | 构造案例，不外推真实人群效果 |
| 官方条款集 | 11 条政策原文 | Policy2Rule 基准 | 金标准由项目组构造，非独立专家评测 |
| 合成家庭 | 项目内生成 240 例 | 主动提问/消融 | 不含真实个人信息 |
| 高风险集 | 项目内生成 100 例 | 安全回归 | 不称独立红队 |
| OCR 合成图 | 项目内生成 16 张 | 流程验证 | 不称真实材料准确率 |

### 6.1 隐私最小化

- 演示数据默认合成；真实姓名、身份证、银行卡等不是资格预判必填项。
- 本地部署优先；上传材料先提示脱敏，日志记录事件不记录原文敏感字段。
- 原始专家表和未来真人试点表不进入公开发布包；对外只提供聚合结果。
- 数据库、日志、临时文件和模型权重不打入源码发布包。

## 07 功能系统

| 模块 | 主要功能 | 对应痛点 |
| --- | --- | --- |
| 居民智能导办 | 诉求解析、主动补问、资格预判、材料清单、办理指引 | 群众不知道问什么、准备什么 |
| 政策证据检索 | 地区/日期过滤、逐字引文、来源定位、版本排除说明 | 无法确认信息来自哪一版政策 |
| 材料智能预检 | OCR 候选字段、图像质量提醒、人工确认 | 材料不齐导致往返 |
| 经办工作台 | 五事项摘要、缺失信息、风险标记、证据核验 | 基层重复询问与口径不一 |
| 治理工作台 | 候选规则、冲突检测、版本差异、影响分析、双审发布 | 政策更新难维护、改动不可控 |
| 评审演示中心 | 六条固定可复现演示路径 | 现场演示不可控 |
| 可信度中心 | 数据、评测、依赖、安全、模型状态统一呈现 | 漂亮页面缺少底层证据 |

### 7.1 关键交互原则

- 任何结果先给状态与下一步，再展示技术细节。
- 把“不知道”作为合法答案；不使用红色制造不必要焦虑。
- 紧急风险信息固定置顶并提供线下求助路径。
- 移动端侧栏、键盘焦点、错误提示和空状态均可操作。

# 08 实验设计与结果

**口径说明** 除官方条款来自真实政策外，本节多项数据为项目内冻结基准、合成测试或专家构造案例。它们用于证明技术机制和可复现性，不代表真实群众满意度、办事成功率或社会效益。

## 8.1 推理一致性

专家构造金标准包含 120 条原始案例，去重后 107 条、535 个事项判断。当前确定性规则在该冻结集上严格一致率 100%，自动覆盖率 81.5%，其余 18.5% 主动保留不确定并转人工。该数字只说明与该构造金标准一致。

## 8.2 检索与问答

| 指标 | 结果 | 基准性质 |
| --- | --- | --- |
| Recall@1 | 0.9167 | 12 条项目内检索问题 |
| Recall@3 / @5 | 1.0000 / 1.0000 | 项目内冻结基准 |
| MRR | 0.9583 | 项目内冻结基准 |
| 意图分类 | 朴素贝叶斯 0.95；关键词 0.75 | 20 条内部合成问题 |
| 证据逐字审计 | 18/18 | 来源快照逐字子串核验 |
| Qwen3 画像字段 F1 | 1.000；P95 2.592 秒 | 40 条内部合成语句；RTX 4060 GPU |
| 混合检索实际路由 | 12/12；P95 430 毫秒 | Qwen3 Embedding；项目内问题 |

## 8.3 主动提问

| 指标 | 主动策略 | 对照 |
| --- | --- | --- |
| 案例数 | 240 | 同一冻结集 |
| 平均问题数 | 8.25 | 固定完整表单 17 |

| 指标 | 主动策略 | 对照 |
| --- | --- | --- |
| 减少比例 | 51.47% | 相对完整表单 |
| 状态一致性 | 100% | 与完整事实推理一致 |
| 紧急风险漏检 | 0 | 项目内合成场景 |

## 8.4 政策编译

| 指标 | 结果 | 解释 |
| --- | --- | --- |
| 官方条款数 | 11 | 真实政策原文，金标准为项目组构造 |
| 金额/日期抽取准确率 | 1.000 | 条款级严格匹配 |
| 条件字段 F1 | 0.727 | 复杂条件仍是后续重点 |
| 参数 F1 | 0.500 | 阈值、单位和例外结构仍需模型增强 |
| 逐字证据锚定率 | 1.000 | 候选引文均为原文子串 |

## 8.5 性能与供应链

| 并发 | 请求数 | P95 | 吞吐 | 错误 |
| --- | --- | --- | --- | --- |
| 1 | 60 | 25.6 ms | 0.0 | 0 |
| 5 | 60 | 58.8 ms | 0.0 | 0 |
| 10 | 60 | 201.2 ms | 0.0 | 0 |
| 20 | 60 | 369.0 ms | 0.0 | 0 |
| 30 | 60 | 439.8 ms | 0.0 | 0 |

测试通过本机回环网络请求真实 Uvicorn 服务，非生产压测。依赖锁定 46 项，当前漏洞报告记录已知漏洞 0 项；软件物料清单和哈希清单随包提供。

# 09 工程实现

| 工程项 | 实现 |
| --- | --- |
| 后端 | Python 3.12 + FastAPI + Pydantic；分层服务；OpenAPI 接口 |
| 前端 | 原生模块化 Web UI；响应式导航；离线 Service Worker；无框架锁定 |
| 存储 | SQLite 本地库；版本化政策、规则、审计事件 |
| AI 运行 | Qwen3 4B + Qwen3 Embedding 0.6B 已在 RTX 4060 实测；确定性底座可见降级 |
| 测试 | Pytest 64 项；前端路由契约；高风险 100 例；复现脚本 |
| 持续集成 | GitHub Actions：依赖安装、测试、项目校验、评测、pip check |
| 供应链 | requirements.lock、SBOM、依赖漏洞审计、数据/源码哈希 |
| 启动停止 | PowerShell 脚本检测端口和 PID，避免重复实例与僵尸进程 |

## 9.1 可复现入口

| 命令 | 作用 |
| --- | --- |
| .\start.ps1 | 创建/使用虚拟环境并启动本地系统 |
| .\stop.ps1 | 仅停止项目记录的服务进程 |
| .\reproduce_phase12.ps1 | 重跑主动提问、消融、安全、清单、SBOM 与并发评测 |
| python -m pytest | 执行全部自动化测试 |
| python scripts/check_project.py | 检查证据、依赖、版本和安全报告完整性 |

## 9.2 版本与变更管理

项目已建立 Git 基线，应用、缓存、静态资源和包元数据统一为 V0.7.0。运行数据库、日志、真人数据、专家原表、临时文件和模型权重均由忽略规则隔离，避免误提交。

# 10 差异化与推广

| 对比维度 | 通用聊天机器人 | 惠民智导 |
| --- | --- | --- |
| 答案生成 | 依赖大模型自由生成 | 规则裁决 + 原文证据 + 独立校验 |
| 政策时间 | 易混用新旧版本 | 地区与日期双过滤，展示排除版本 |
| 信息缺失 | 倾向补全或猜测 | 三值逻辑保留 UNKNOWN |
| 政策更新 | 修改提示词或知识库 | 候选编译、差异、影响分析、人工发布 |
| 可复现 | 模型更新后结果漂移 | 冻结规则和评测集可回放 |
| 离线与隐私 | 常依赖云端 API | 单机本地优先，模型不可用可降级 |

## 10.1 平台化路线

通用内核由 PolicySource、PolicyVersion、RuleCandidate、Rule、Evidence、CaseFact、Decision 与 AuditEvent 八类对象构成。新增场景主要替换字段字典、政策源、规则包和办理事项，无需重写可信链路。优先拓展助学金、医保待遇和就业补贴等同样具有时间边界、资格条件和材料清单的政策服务。

# 11 风险、伦理与合规

| 风险 | 缓解措施 | 剩余风险 |
| --- | --- | --- |
| 错误资格判断 | 三值逻辑、人工复核、非审批声明、回归集 | 政策解释仍需主管部门确认 |
| 政策过期 | 有效期、查询日期、哈希与版本隔离 | 来源网页变更需定期更新 |
| 模型幻觉 | 原文子串门、Schema、独立验证器 | 复杂条款抽取 F1 仍需提升 |
| 提示注入 | 忽略指令型内容、字段白名单、高风险回归 | 新型攻击需持续补充 |
| 隐私泄露 | 最少字段、本地优先、敏感目录隔离 | 真实部署需完善访问控制与留存策略 |
| 数字鸿沟 | 简洁语言、线下办理指引、经办端协助 | 无障碍测试仍需真人参与 |
| 指标误用 | 每项指标标注数据性质与边界 | 真实效果必须由真人试点产生 |

**伦理底线** 系统帮助用户理解政策和准备材料，不替代行政机关作出资格认定；不鼓励规避核验；不生成虚假证明；无法确认时明确说不知道。

# 12 实施计划与团队分工

| 角色 | 主要职责 | 可交叉备份 |
| --- | --- | --- |
| 成员 A · AI/数据 | Policy2Rule、本地模型、检索、评测集与实验 | 安全测试、数据治理 |
| 成员 B · 后端/可信 | 时态规则、三值推理、API、审计、发布门 | 部署、性能与供应链 |
| 成员 C · 前端/材料 | 产品交互、响应式界面、演示中心、方案与答辩 | 测试、视频脚本与现场演示 |

## 12.1 赛前里程碑

| 阶段 | 完成标准 |
| --- | --- |
| M1 技术冻结 | 模型实测报告、全部测试、项目校验、漏洞扫描通过 |
| M2 外部验证 | 真人可用性试点、专家复核、问题闭环；若无则如实标注未完成 |
| M3 材料冻结 | 方案 PDF <10MB、PPT 转 PDF、证据 PDF、3–5 分钟视频 |
| M4 提交演练 | 全新 Windows 环境按 README 启动；六条演示路径完整；断网降级 |

# 13 提交清单与声明

| 材料 | 状态/要求 |
| --- | --- |
| 作品名称 | 惠民智导可信政策智能平台（20 字以内） |
| 作品简介 | 300 字以内，问题—方案—创新—边界—应用 |

| 材料 | 状态/要求 |
| --- | --- |
| 作品方案 | 本 DOCX 及导出 PDF；提交前确认小于 10MB |
| 答辩材料 | 15 页 PPTX，并转换为 PDF 提交 |
| 演示视频 | 需团队真人录制 3–5 分钟 MP4，建议 1080p，文件不超过 300MB |
| 佐证材料 | 评测报告、专家复核、真人试点（若完成）、软件著作或合作证明（若有）合并 PDF |
| 源码与模型说明 | 发布 ZIP + SHA-256；模型权重不入包，提供官方下载和哈希/版本说明 |
| 网盘 | 由团队按“团队编号-赛题名称-作品名称-XX”上传永久链接 |

## 13.1 当前仍需真人完成

- 填写最终团队编号、正式赛题名称、队员与学校信息。
- 组织真实参与者完成可用性试点并保留知情同意；不能以 AI 生成记录代替。
- 真人录制演示视频、检查声音和隐私遮挡。
- 在另一台干净 Windows 电脑完成第三方安装验收并签字。
- 完成最终盖章/签字、网盘上传和竞赛平台提交。

## 13.2 真实性声明

本文引用的实验结果均可由仓库脚本复现，并在文字中标明数据性质。项目未把项目组生成的合成数据描述为真人数据，未把项目组构造的金标准描述为独立第三方评估，未把导办结果描述为行政审批结论。若后续完成真人试点，应以原始记录、统计脚本和问题闭环表更新本节，而不是覆盖现有实验口径。

**结论** 惠民智导已经形成可运行、可解释、可拒答、可审计、可复现的软件内核，本地生成与向量模型均已完成 GPU 冻结评测。国赛竞争力来自“高风险政策智能的可信工程方法”，而非单一模型规模；最终提交前仍需真实外部验证、干净电脑验收与真人视频。