惠民智导

可信政策智能软件平台

项目说明书

一句话定义 采用受约束神经符号架构，把本地模型、时态规则、三值逻辑、混合检索、政策编译与独立安全校验组合为可追溯、可拒答、可回归验证的政策智能软件。

团队：策马奔腾

队长：林琪东　队员：罗晓蓝

学校：广州软件学院

版本：V0.7.1 | 文档日期：2026-10-03

数据科学与大数据技术 · 单机 RTX 4060

作品摘要

社会救助政策专业、分散且持续更新，群众难以判断“当前适用哪一版、还缺什么信息、依据在哪里”，基层人员也面临重复解释、规则维护和错误传播风险。惠民智导将社会救助作为首个深度验证场景，构建政策摄取、Policy2Rule 候选编译、时态规则推理、主动提问、证据检索、材料预检、影响分析与人工发布门的一体化平台。

系统坚持“模型理解、规则裁决、原文举证、人工发布”：模型只做意图识别、信息抽取和候选结构化；资格结果由版本化规则与三值逻辑计算；独立校验器阻止无证据结论、越权审批和提示注入；每个结论均回链逐字政策原文。

可信边界 本说明书不宣称已取得真实群众应用成效。现有数字来自项目内合成测试、官方条款基准和专家构造金标准；真人试点与第三方证明作为外部验证任务单独管理。

核心成果速览

维度	当前可验证结果	证据文件
安全	高风险集 100/100 通过	high_risk_safety_report.json
检索	内部基准 R@3=1.000，MRR=0.958	retrieval_report.json
主动提问	240 合成案例；较 17 字段表单减少 51.47%	active_question_report.json
政策编译	11 条官方条款；原文锚定率 1.000	policy_compiler_real_report.json
并发	1/5/10/20/30 并发零错误；30 并发 P95 439.8ms	http_concurrency_report.json
工程	64 项自动测试通过；锁定依赖 46 项；已知漏洞 0	pytest / vulnerability report

目录

章节	内容	章节	内容
01	问题与价值	08	实验设计与结果
02	产品与用户旅程	09	工程实现
03	总体架构	10	差异化与推广
04	AI 核心创新	11	风险与伦理
05	可信安全机制	12	团队与实施
06	数据与知识治理	13	使用与交付
07	功能系统		

01 问题与价值

1.1 社会痛点

对象	高频痛点	传统方式的限制
困难群众	术语难懂、条件繁多、材料不清、政策版本难辨	网页搜索和电话咨询难形成个性化、可追溯结论
基层经办	重复问询、信息缺失、口径更新不一致	静态问答库无法表达例外、缺失值与时间边界
政策管理者	政策转规则慢，变更影响不可见	人工维护难发现冲突，发布前缺少回归验证
监督者	难追溯结论由来，模型可能自信编造	通用大模型缺少发布权边界和原文级证据链

1.2 项目价值

- 把“查政策”升级为“问最少的问题—保留不知道—给出下一步—回链原文”。
- 把“写规则”升级为“模型候选抽取—Schema 校验—原文锚定—影响分析—人工双审”。
- 把“模型回答”约束为不越权的辅助决策，避免将导办误包装为审批。
- 以社会救助验证通用内核，可迁移至医保、助学、养老、就业补贴等政策服务。

1.3 目标用户与边界

居民端提供资格预判、信息补问、材料清单和办理指引；经办端提供结构化摘要、证据核对和人工复核；治理端提供政策版本、候选规则、影响分析与发布门。系统输出均为导办建议，不替代政府审批，不生成虚假证明，不收集非必要身份信息。

02 产品与用户旅程

阶段	系统动作	可信产物
1. 表达诉求	自然语言输入或选择示例家庭	意图、地区、查询日期、已知事实
2. 主动补问	按预期信息增益选择下一问题，可跳过	UNKNOWN 保留，不强迫猜测
3. 资格预判	时态规则 + 三值逻辑 + 独立校验	符合/可能符合/信息不足/需人工复核
4. 原文举证	BM25/混合检索，按日期过滤政策版本	逐字引文、来源、定位、哈希
5. 材料预检	OCR 抽取候选字段，人工确认	缺件提醒与风险提示，不替代原件
6. 办理导向	匹配办事机构和事项	地址、电话、材料清单、行动步骤
7. 政策更新	Policy2Rule 候选编译与影响分析	差异报告、回归结果、人工发布记录

演示闭环 演示者可在“场景验证中心”按 A–F 六个案例复现：正常家庭、信息不足、紧急风险、政策版本差异、候选规则影响分析、越权与注入拒绝。

03 总体架构

层级	关键组件	设计原则
交互层	居民端、经办端、场景验证中心、治理工作台	同一事实模型，不做孤立演示页
AI 理解层	意图分类、字段抽取、OCR、候选政策编译	模型输出仅为候选，统一 Schema 约束
推理层	时态规则、三值逻辑、主动提问、冲突检测	确定性可复现；UNKNOWN 为一等状态
证据层	政策切片、版本选择、BM25/向量接口、逐字引文	结论必须有原文证据；过期版本隔离
安全层	独立校验器、越权检测、注入防护、人工发布门	失败时拒答或降级，不静默放行
工程层	FastAPI、SQLite、审计日志、离线部署、CI	单机可运行、可测、可打包、可复现

3.1 受约束神经符号路线

神经模型擅长理解自然语言和生成结构化候选；符号规则擅长处理政策阈值、例外、时间和可复现裁决。系统以“候选—校验—发布”隔离两者：任何模型输出都不能直接进入正式规则库，也不能绕过证据与人工复核。

输入	AI 处理	约束	输出
群众描述	意图与事实抽取	字段白名单、拒绝注入	候选事实 + 置信度
政策原文	条款切分与规则候选	Schema、原文子串、类型检查	待审候选规则
咨询问题	语义召回候选	日期/地区过滤、原文引用	证据片段与来源
家庭事实	不由大模型裁决	时态规则 + 三值逻辑	可解释导办状态

04 AI 核心创新

4.1 Policy2Rule：政策原文到候选规则

系统从官方条款中抽取适用对象、条件字段、比较符、阈值、例外、有效期和逐字证据，生成候选规则。候选必须通过 JSON Schema、字段白名单、运算符白名单、证据子串校验和版本完整性检查，之后才能进入影响分析和人工双审。

创新点	实现	避免的风险
逐字锚定	candidate.evidence_quote 必须是源文档连续子串	模型“总结正确但出处虚构”
类型化条件	字段、运算符和值独立建模	自然语言规则不可计算
版本化发布	effective_from/to + region + source hash	新旧政策混用
影响分析	候选规则对冻结案例集批量回放	修改一个阈值导致隐蔽回归
人工发布门	模型无 publish 权限，异常候选自动阻断	自动化越权发布

4.2 主动信息增益提问

系统不固定询问全部字段，而是计算每个缺失事实对候选事项状态的区分能力，优先询问能最大幅度减少不确定性的字段。用户可选择“不知道/跳过”，系统不会把未知值改写为否定值。

4.3 时态证据检索

检索前先按地区和查询日期筛选适用版本，再在适用政策片段上执行关键词或向量召回；过期、未生效和跨地区片段进入排除列表，可在界面解释“为何未采用”。这使检索不仅回答“相关不相关”，还回答“在这个日期是否有效”。

4.4 独立安全验证

最终输出由与生成模块分离的验证器检查：是否越权声称审批、是否包含无来源结论、是否遗漏紧急求助提示、是否将 UNKNOWN 强制二值化、是否响应提示注入、是否尝试自动发布。失败时返回受控拒答或人工复核。

AI 的真正贡献 创新不是给网页加聊天框，而是让模型进入政策编译和证据检索的高价值环节，同时用符号约束、时间边界和独立校验把生成式风险关进工程护栏。

05 可信安全机制

机制	触发条件	系统行为	可验证证据
三值逻辑	关键字段缺失	返回 UNKNOWN/信息不足并继续补问	ablation_report.json
时态选择	同政策多版本	仅选择查询日期有效版本	retrieval benchmark
证据门	结论无逐字引文	阻断或转人工	evidence_quote_audit.json
注入防护	要求忽略规则/伪造身份	不提取关键事实，保留警示	100 例安全集
发布门	候选规则请求直接生效	禁止自动发布，要求双审	publish gate tests
越权防护	询问是否“已批准”	声明仅供导办，不替代审批	out-of-scope tests

机制	触发条件	系统行为	可验证证据
安全降级	本地模型不可用	切回确定性管线并显示真实状态	AI readiness endpoint

5.1 高风险测试集

项目构建 100 条项目内高风险测试，覆盖 UNKNOWN 保留 25 条、时间边界 20 条、越权问题 20 条、提示注入 20 条和发布门 15 条。当前版本通过 100/100。该结果用于开发回归，不等同于独立红队或真实群众试点。

5.2 消融证明

八组消融实验分别关闭三值逻辑、时态选择、证据门、Schema、冲突检测、主动提问、人工发布门和越权防护，观察不安全输出或额外负担。关闭二值保护会迫使 204/240 个信息不足案例产生武断结果；关闭证据门会使 4320 个条件失去可追溯证据；固定提问平均额外增加 2.75 个问题。

06 数据与知识治理

数据资产按来源、用途、是否独立、是否含个人信息、哈希和生成方式登记。官方政策文档保留本地快照、来源链接、发布日期、适用地区和 SHA-256；评测数据区分官方条款、专家构造金标准和项目内合成数据。

资产类型	来源	用途	声明
政策证据包	政府公开文件/网页本地快照	规则和证据	逐字引用并记录哈希
专家金标准	专家 A/B 标注与 C 裁决	确定性推理评测	构造案例，不外推真实人群效果
官方条款集	11 条政策原文	Policy2Rule 基准	金标准由项目组构造，非独立专家评测
合成家庭	项目内生成 240 例	主动提问/消融	不含真实个人信息
高风险集	项目内生成 100 例	安全回归	不称独立红队
OCR 合成图	项目内生成 16 张	流程验证	不称真实材料准确率

6.1 隐私最小化

- 演示数据默认合成；真实姓名、身份证、银行卡等不是资格预判必填项。
- 本地部署优先；上传材料先提示脱敏，日志记录事件不记录原文敏感字段。
- 原始专家表和未来真人试点表不进入公开发布包；对外只提供聚合结果。
- 数据库、日志、临时文件和模型权重不打入源码发布包。

07 功能系统

模块	主要功能	对应痛点
居民智能导办	诉求解析、主动补问、资格预判、材料清单、办理指引	群众不知道问什么、准备什么
政策证据检索	地区/日期过滤、逐字引文、来源定位、版本排除说明	无法确认信息来自哪一版政策
材料智能预检	OCR 候选字段、图像质量提醒、人工确认	材料不齐导致往返
经办工作台	五事项摘要、缺失信息、风险标记、证据核验	基层重复询问与口径不一
治理工作台	候选规则、冲突检测、版本差异、影响分析、双审发布	政策更新难维护、改动不可控
场景验证中心	六条固定可复现演示路径	现场演示不可控
可信度中心	数据、评测、依赖、安全、模型状态统一呈现	漂亮页面缺少底层证据

7.1 关键交互原则

- 任何结果先给状态与下一步，再展示技术细节。
- 把“不知道”作为合法答案；不使用红色制造不必要焦虑。
- 紧急风险信息固定置顶并提供线下求助路径。
- 移动端侧栏、键盘焦点、错误提示和空状态均可操作。

08 实验设计与结果

口径说明 除官方条款来自真实政策外，本节多项数据为项目内冻结基准、合成测试或专家构造案例。它们用于证明技术机制和可复现性，不代表真实群众满意度、办事成功率或社会效益。

8.1 推理一致性

专家构造金标准包含 120 条原始案例，去重后 107 条、535 个事项判断。当前确定性规则在该冻结集上严格一致率 100%，自动覆盖率 81.5%，其余 18.5% 主动保留不确定并转人工。该数字只说明与该构造金标准一致。

8.2 检索与问答

指标	结果	基准性质
Recall@1	0.9167	12 条项目内检索问题
Recall@3 / @5	1.0000 / 1.0000	项目内冻结基准
MRR	0.9583	项目内冻结基准
意图分类	朴素贝叶斯 0.95；关键词 0.75	20 条内部合成问题
证据逐字审计	18/18	来源快照逐字子串核验
Qwen3 画像字段 F1	1.000；P95 2.592 秒	40 条内部合成语句；RTX 4060 GPU
混合检索实际路由	12/12；P95 430 毫秒	Qwen3 Embedding；项目内问题

8.3 主动提问

指标	主动策略	对照
案例数	240	同一冻结集
平均问题数	8.25	固定完整表单 17

指标	主动策略	对照
减少比例	51.47%	相对完整表单
状态一致性	100%	与完整事实推理一致
紧急风险漏检	0	项目内合成场景

8.4 政策编译

指标	结果	解释
官方条款数	11	真实政策原文，金标准为项目组构造
金额/日期抽取准确率	1.000	条款级严格匹配
条件字段 F1	0.727	复杂条件仍是后续重点
参数 F1	0.500	阈值、单位和例外结构仍需模型增强
逐字证据锚定率	1.000	候选引文均为原文子串

8.5 性能与供应链

并发	请求数	P95	吞吐	错误
1	60	25.6 ms	0.0	0
5	60	58.8 ms	0.0	0
10	60	201.2 ms	0.0	0
20	60	369.0 ms	0.0	0
30	60	439.8 ms	0.0	0

测试通过本机回环网络请求真实 Uvicorn 服务，非生产压测。依赖锁定 46 项，当前漏洞报告记录已知漏洞 0 项；软件物料清单和哈希清单随包提供。

09 工程实现

工程项	实现
后端	Python 3.12 + FastAPI + Pydantic；分层服务；OpenAPI 接口
前端	原生模块化 Web UI；响应式导航；离线 Service Worker；无框架锁定
存储	SQLite 本地库；版本化政策、规则、审计事件
AI 运行	Qwen3 4B + Qwen3 Embedding 0.6B 已在 RTX 4060 实测；确定性底座可见降级
测试	Pytest 64 项；前端路由契约；高风险 100 例；复现脚本
持续集成	GitHub Actions：依赖安装、测试、项目校验、评测、pip check
供应链	requirements.lock、SBOM、依赖漏洞审计、数据/源码哈希
启动停止	PowerShell 脚本检测端口和 PID，避免重复实例与僵尸进程

9.1 可复现入口

命令	作用
.\start.ps1	创建/使用虚拟环境并启动本地系统
.\stop.ps1	仅停止项目记录的服务进程
.\reproduce_phase12.ps1	重跑主动提问、消融、安全、清单、SBOM 与并发评测
python -m pytest	执行全部自动化测试
python scripts/check_project.py	检查证据、依赖、版本和安全报告完整性

9.2 版本与变更管理

项目已建立 Git 基线，应用、缓存、静态资源和包元数据统一为 V0.7.1。运行数据库、日志、真人数据、专家原表、临时文件和模型权重均由忽略规则隔离，避免误提交。

10 差异化与推广

对比维度	通用聊天机器人	惠民智导
答案生成	依赖大模型自由生成	规则裁决 + 原文证据 + 独立校验
政策时间	易混用新旧版本	地区与日期双过滤，展示排除版本
信息缺失	倾向补全或猜测	三值逻辑保留 UNKNOWN
政策更新	修改提示词或知识库	候选编译、差异、影响分析、人工发布
可复现	模型更新后结果漂移	冻结规则和评测集可回放
离线与隐私	常依赖云端 API	单机本地优先，模型不可用可降级

10.1 平台化路线

通用内核由 PolicySource、PolicyVersion、RuleCandidate、Rule、Evidence、CaseFact、Decision 与 AuditEvent 八类对象构成。新增场景主要替换字段字典、政策源、规则包和办理事项，无需重写可信链路。优先拓展助学金、医保待遇和就业补贴等同样具有时间边界、资格条件和材料清单的政策服务。

11 风险、伦理与合规

风险	缓解措施	剩余风险
错误资格判断	三值逻辑、人工复核、非审批声明、回归集	政策解释仍需主管部门确认
政策过期	有效期、查询日期、哈希与版本隔离	来源网页变更需定期更新
模型幻觉	原文子串门、Schema、独立验证器	复杂条款抽取 F1 仍需提升
提示注入	忽略指令型内容、字段白名单、高风险回归	新型攻击需持续补充
隐私泄露	最少字段、本地优先、敏感目录隔离	真实部署需完善访问控制与留存策略
数字鸿沟	简洁语言、线下办理指引、经办端协助	无障碍测试仍需真人参与
指标误用	每项指标标注数据性质与边界	真实效果必须由真人试点产生

伦理底线 系统帮助用户理解政策和准备材料，不替代行政机关作出资格认定；不鼓励规避核验；不生成虚假证明；无法确认时明确说不知道。

12 团队与实施

角色	主要职责	可交叉备份
林琪东 · 队长	总体架构、后端与可信推理、本地模型集成、部署验收	实验复现、现场演示
罗晓蓝 · 队员	前端交互、数据与政策材料整理、文档与测试	材料预检、现场演示

团队名称为策马奔腾，学校为广州软件学院。

12.1 交付里程碑

阶段	完成标准
M1 技术冻结	模型实测报告、全部测试、项目校验、漏洞扫描通过
M2 外部验证	真人可用性试点、专家复核、问题闭环；若无则如实标注未完成
M3 材料冻结	方案 PDF <10MB、PPT 转 PDF、证据 PDF、3–5 分钟视频
M4 提交演练	全新 Windows 环境按 README 启动；六条演示路径完整；断网降级

13 使用与交付

13.1 本地启动

在 Windows PowerShell 中进入软件目录，首次运行 .\setup.ps1 安装依赖，之后运行 .\start.ps1 启动。浏览器访问 http://127.0.0.1:8000。结束时运行 .\stop.ps1。若本机已安装 Qwen3 模型，启动脚本会自动选择混合检索；模型不可用时安全降级到确定性管线。

13.2 建议演示顺序

时间	页面	展示重点
0:00–0:30	项目总览	社会痛点、可信边界、14 份官方来源
0:30–1:35	智能预筛	合成家庭、主动补问、三值结论、下一步
1:35–2:15	政策证据	逐字原文、版本日期、来源定位
2:15–2:55	材料预检	清晰与模糊材料、OCR 候选、人工复核
2:55–3:35	场景验证	信息不足、紧急风险、新旧政策切换
3:35–4:00	可信治理	规则候选、影响分析、安全降级与审计

13.3 交付文件

材料	状态/要求
作品名称	惠民智导可信政策智能平台（20 字以内）
作品简介	300 字以内，问题—方案—创新—边界—应用
作品方案	本 DOCX 及导出 PDF；提交前确认小于 10MB
答辩材料	15 页 PPTX，并转换为 PDF 提交
演示视频	需团队真人录制 3–5 分钟 MP4，建议 1080p，文件不超过 300MB
佐证材料	评测报告、专家复核、真人试点（若完成）、软件著作或合作证明（若有）合并 PDF
源码与模型说明	发布 ZIP + SHA-256；模型权重不入包，提供官方下载和哈希/版本说明
上传文件	由团队按指定平台的文件命名和大小要求提交

13.4 当前仍需真人完成

- 填写团队编号、正式赛题名称和联系方式等平台专用信息。
- 组织真实参与者完成可用性试点并保留知情同意；不能以 AI 生成记录代替。
- 真人录制演示视频、检查声音和隐私遮挡。

- 在另一台干净 Windows 电脑完成第三方安装验收并签字。
- 完成最终盖章、签字、文件上传和指定平台提交。

13.5 真实性声明

本文引用的实验结果均可由仓库脚本复现，并在文字中标明数据性质。项目未把项目组生成的合成数据描述为真人数据，未把项目组构造的金标准描述为独立第三方评估，未把导办结果描述为行政审批结论。若后续完成真人试点，应以原始记录、统计脚本和问题闭环表更新本节，而不是覆盖现有实验口径。

结论 惠民智导已经形成可运行、可解释、可拒答、可审计、可复现的软件内核，本地生成与向量模型均已完成 GPU 冻结评测。项目的核心价值来自高风险政策智能的可信工程方法，而非单一模型规模；外部验证、干净电脑验收与真人视频仍需由团队真实完成。